
Using Machine Learning to Improve the Performance of Flying Networks

- Francisco Tuna de Andrade
- Pedro Miguel Ferraz Nogueira da Silva

3/08/2018




INSTITUTO DE ENGENHARIA DE SISTEMAS E COMPUTADORES, TECNOLOGIA E CIÊNCIA




Enquadramento

 Uso de redes baseadas em drones (UAV's) como resposta a eventos temporariamente lotados (TCE's)




Objetivos


- Construção de um modelo Machine Learning que preveja as métricas (throughput, delay ou PDR) de uma rede UAV
- Implementação de um algoritmo que encontre a melhor localização dos UAVs para um dado cenário de tráfego gerado




Trabalho desenvolvido



Dataset







- ➤ 3 Drones;
- Altitude de 10 metros;
- Cada zona tem dimensão 30m*30m
- > Tráfego UDP
- ➤ WifiCellRange de 100 metros
- WifiChannelNumber: {36,40,44}
- Métricas a analisar (throughput, delay, pdr)


Processamento dos dados


```
Linha de comandos - python -i build_model.py
array([[[[ 3.
                                                , ..., 0.
                                     0.
                                                , ..., 0.
                       0.
                                     0.
                                               , ..., 0.
          0.
        [ 0.
                                    0.
                                     0.
                                               , ..., Ө.
                     , 0.
                                    0.
                                  j],
                     , 3.
       [[ 3.02953607, 3.06634492, 2.80236837, ..., 0.43139197,
          0.16931388, 0.07336994],
         [ 2.43830285, 2.4803205 , 2.60391312, ..., -0.02806965,
          -0.37829206, -0.51786329],
         [ 1.84706962, 1.89600158, 2.03895751, ..., -0.37829206,
          -0.8641997 , -1.10909652],
        [-1.10909652, -0.8641997 , -0.51786329, ..., 0.94374563,
          0.7373873 , 0.66460316],
        [-1.70032975, -1.10909652, -1.10909652, ..., 1.31438002,
          1.31438002, 1.25583639],
        [-1.10909652, -1.10909652, -1.70032975, ..., 1.25583639,
          1.84706962, 1.84706962]]],
      [[[ 0.
                                     ø.
                                               , ..., 0.
                       0.
                                     0.
        [ 0.
                       0.
                                     0.
        [ 0.
                       0.
                                     3.
                       0.
        [ 0.
                                     0.
        [ 0.
                                     0.
                                  j),
       [[ 7.14390291, 6.14881563, 5.19491291, ..., 4.4517146 ,
          5.19491291, 6.14881563],
        [ 5.47674311, 4.90466431, 3.80958332, ..., 2.9295496 ,
          3.80958332, 4.90466431],
        [ 3.80958332, 3.80958332, 2.54694432, ..., 1.48481447,
          2.54694432, 3.80958332],
        [-4.52621566, -2.85905587, -1.19189607, ..., 0.18922433,
          1.48481447, 2.9295496 ],
         [-4.52621566, -2.85905587, -1.19189607, ..., 1.48481447, 2.54694432, 3.80958332],
        [-2.85905587, -2.16849567, -0.79833303, ..., 2.9295496, 3.80958332, 4.90466431]]]])
>>> throughput train
array([2.689776 , 2.952488 , 2.928736 , ..., 2.805651 , 2.15420875,
       2.665089 1)
```

Fig 2: Dados de treino

```
SCENARIO ROWS = 10 #Number of rows in each scenario
SCENARIO COLUMNS = 10 #Number of columns in each scenario
SCENARIO TOPOLOGIES NO = 200 #Number of topologies by scenario
SCENARIOS NO = 10 #Number of scenarios
TOPOLOGIES TRAINING = 128 #Number of topologies to be used in training
TOPOLOGIES VALIDATION = 32 #Number of topologies to be used in validation
TOPOLOGIES TESTING = 40 #Number of topologies to be used in testing
SCENARIOS TRAINING = [1, 2, 4, 6, 7, 10] #Scenarios to be used in training
SCENARIOS VALIDATION = [5, 9] #Scenarios to be used in validation
SCENARIOS TEST = [3, 8] #Scenarios to be used in testing
DIVISION BY TOPOLOGIES = False #True if division train/validation/test is to be made by topologies
DISTANCE ENCODING = True #True if the topologies should use distance encoding
NORMALIZE DATA = True #True if data should be normalized
USE TRANSFORMATIONS = True #True if data augmentation should be used
CHANNELS LAST = False #True if data to be fit to the model should have channels last format
USE CALLBACKS = False #True if callbacks should be used when training the model
TEST RESULTS = True #True if the program should present the results of the tests
```

Fig 3: Tipos de settings usados





Divisão por cenários (Treino/Teste: 8/2)


	MSE	MAE	MAPE
Throughput	0.833	0.762	17.619
Delay	20609.9	388.687	41.118
PDR	0.041	0.172	29.119

Divisão por topologias (Treino/Teste: 160/40)


	MSE	MAE	MAPE
Throughput	0.176	0.296	7.976
Delay	39241.7	147.179	18.929
PDR	0.003	0.041	6.46

Fig 6: Análise de treino do modelo

Divisão por Cenários:




Divisão por Topologias:



Throughput Loss


Divisão por Cenários:

Divisão por Topologias:



Divisão por Cenários:

Divisão por Topologias:



Comparação com o Ns-3

Model Trained By Division	Scenarios			Topologies		
	Throughput	Delay	PDR	Throughput	Delay	PDR
MAPE	49	66	25	20	48	12

Conclusões

No fim deste trabalho conseguimos tirar algumas conclusões importantes para o futuro aprofundamento deste tema:

- o modelo dá bons resultados, mas necessita de mais dados, principalmente cenários, de forma a dar resultados mais próximos da realidade;
- o número de epochs de treino, no caso do delay, deveria ser aumentado. Acreditamos que com mais de 100 epochs o delay melhora substancialmente;
- o modelo dá melhores resultados quando treinado com distance encoding;
- a divisão por topologias nos dados gera um modelo com melhores resultados;

Feedback

★ O que correu bem?



★ O que correu menos bem?



Questões?

