


# Using Machine Learning to Improve the Performance of Flying Networks

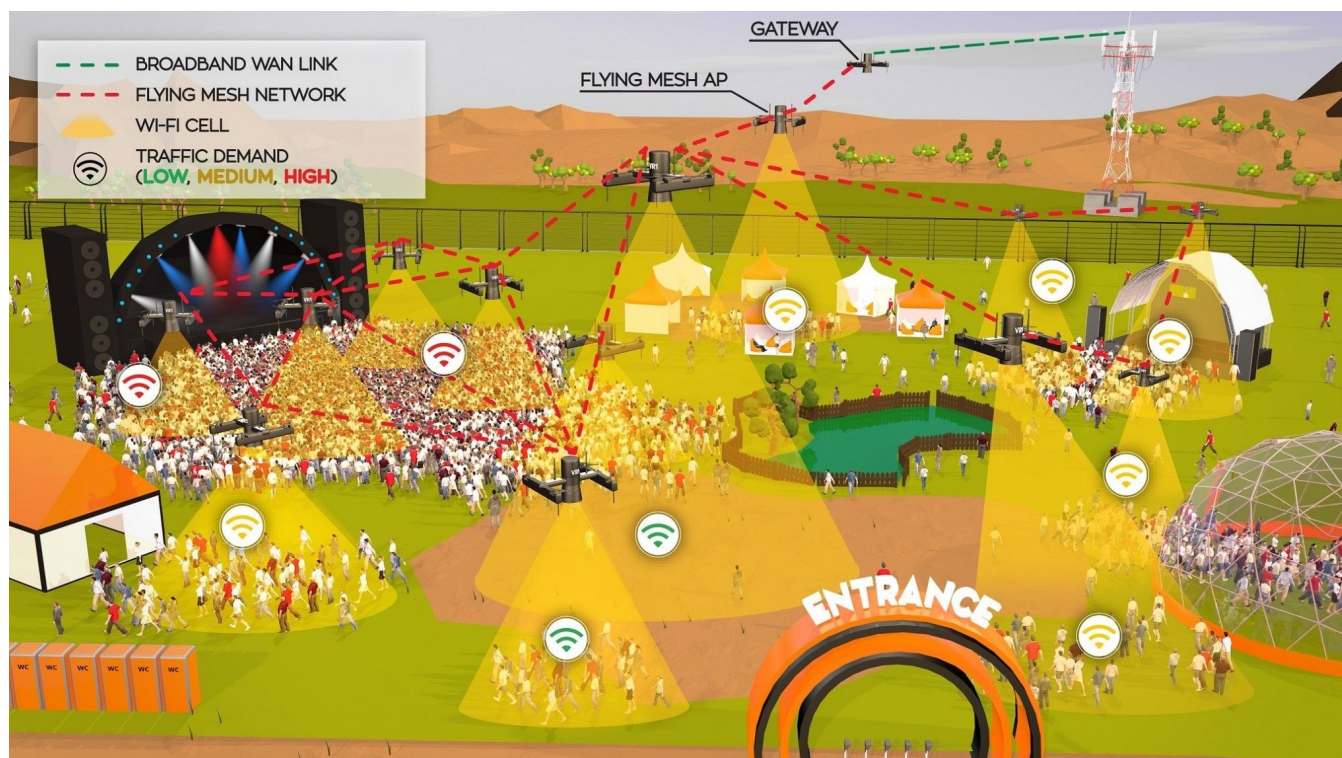
- ❖ Francisco Tuna de Andrade
- ❖ Pedro Miguel Ferraz Nogueira da Silva

3/08/2018




# Enquadramento

- Uso de redes baseadas em drones (UAV's) como resposta a eventos temporariamente lotados (TCE's)

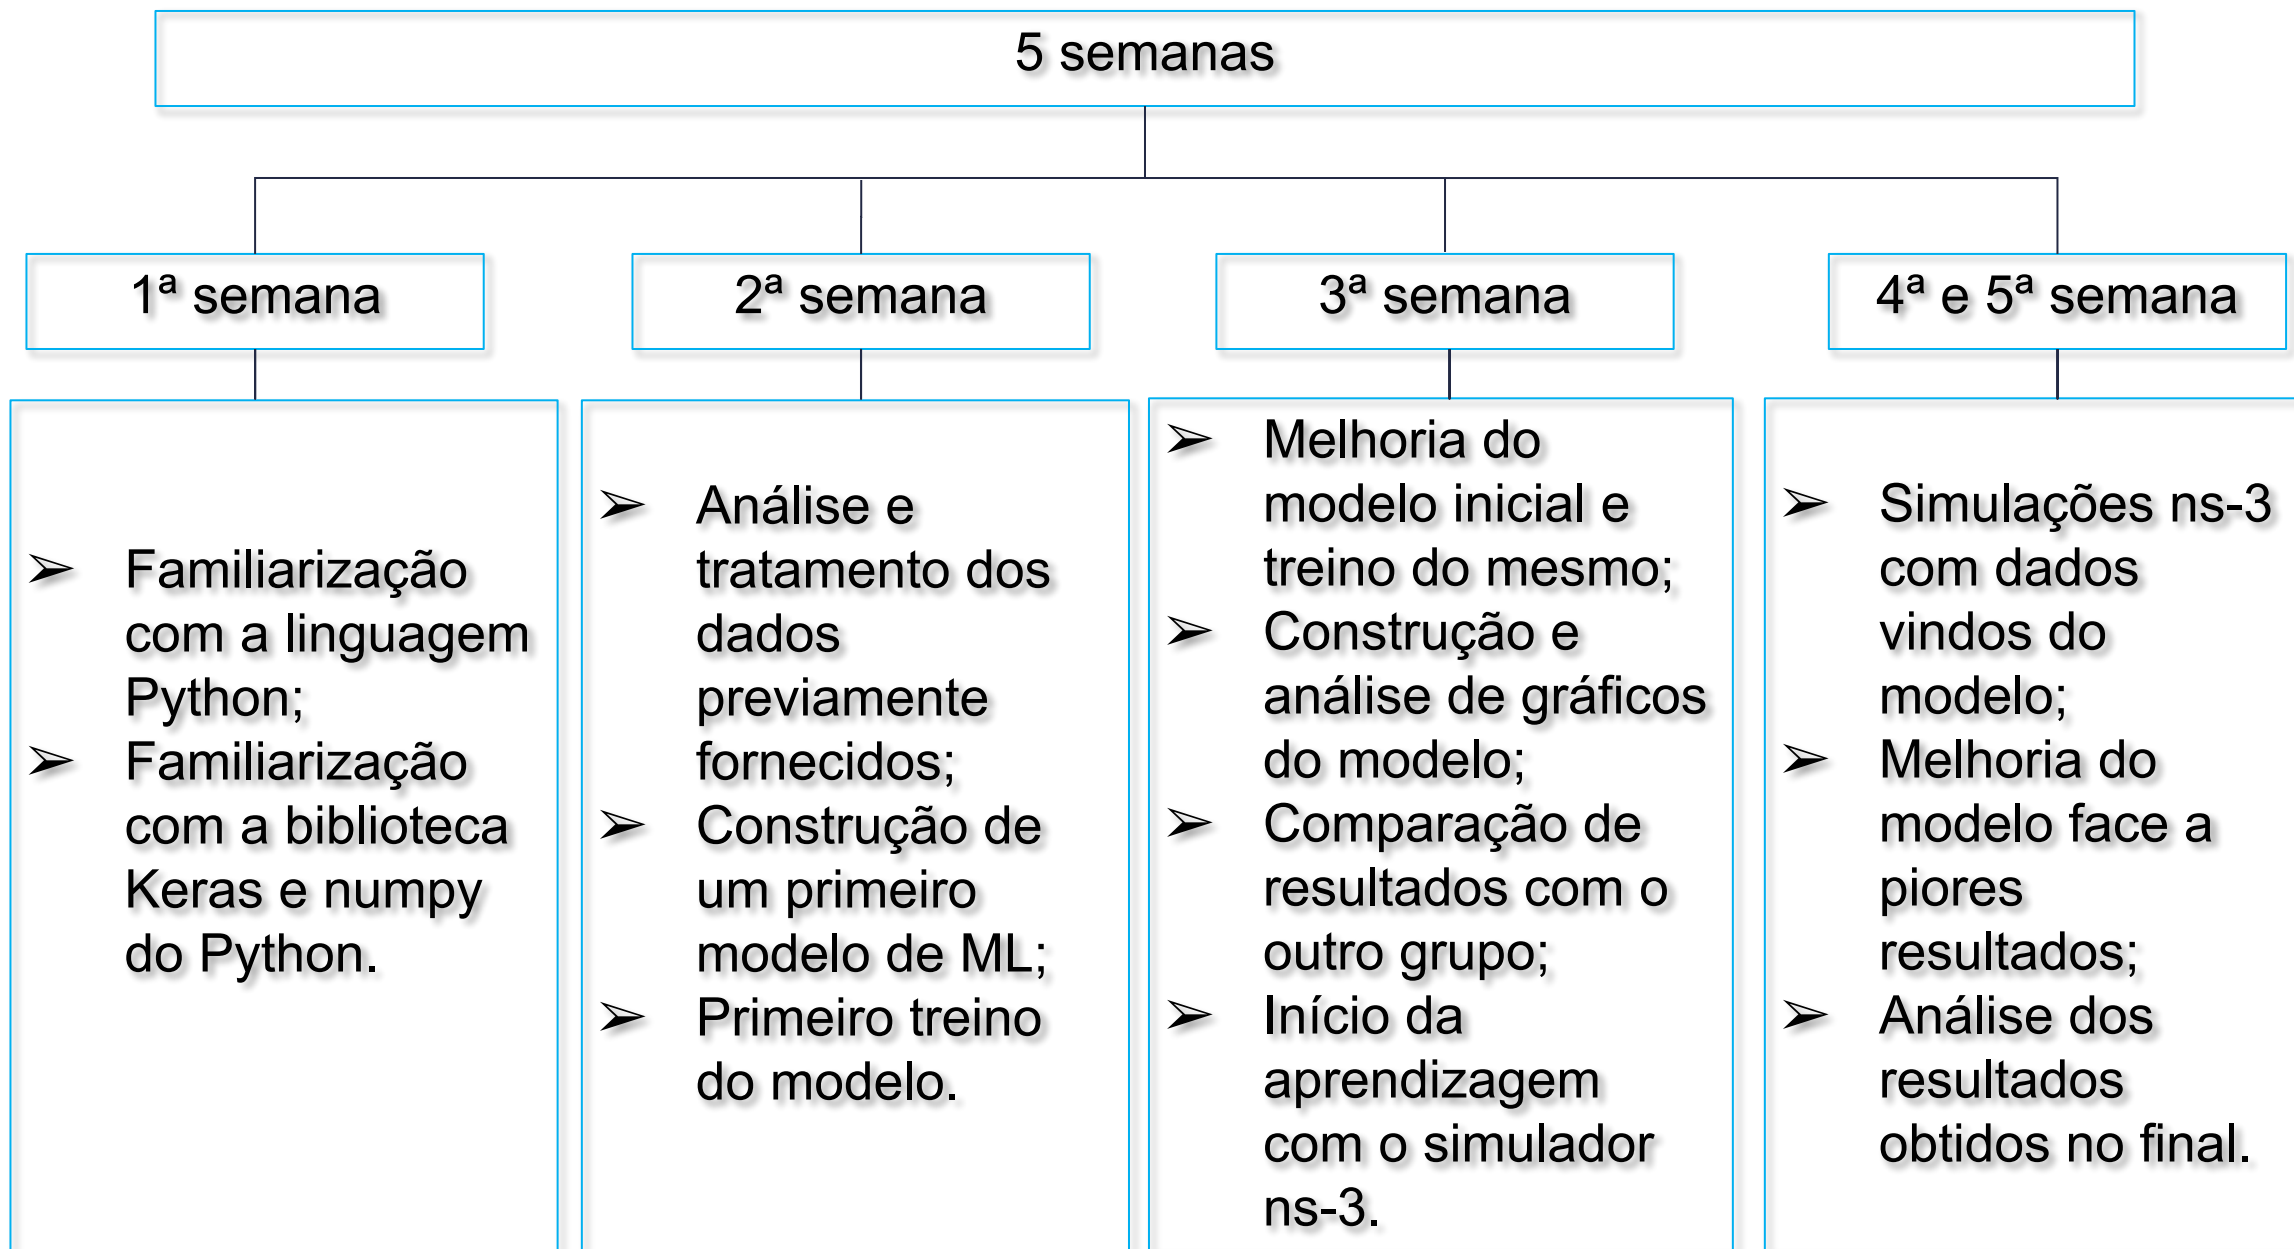


# Objetivos

- Construção de rede neuronal que preveja as métricas (throughput, delay ou pdr) de uma rede UAV



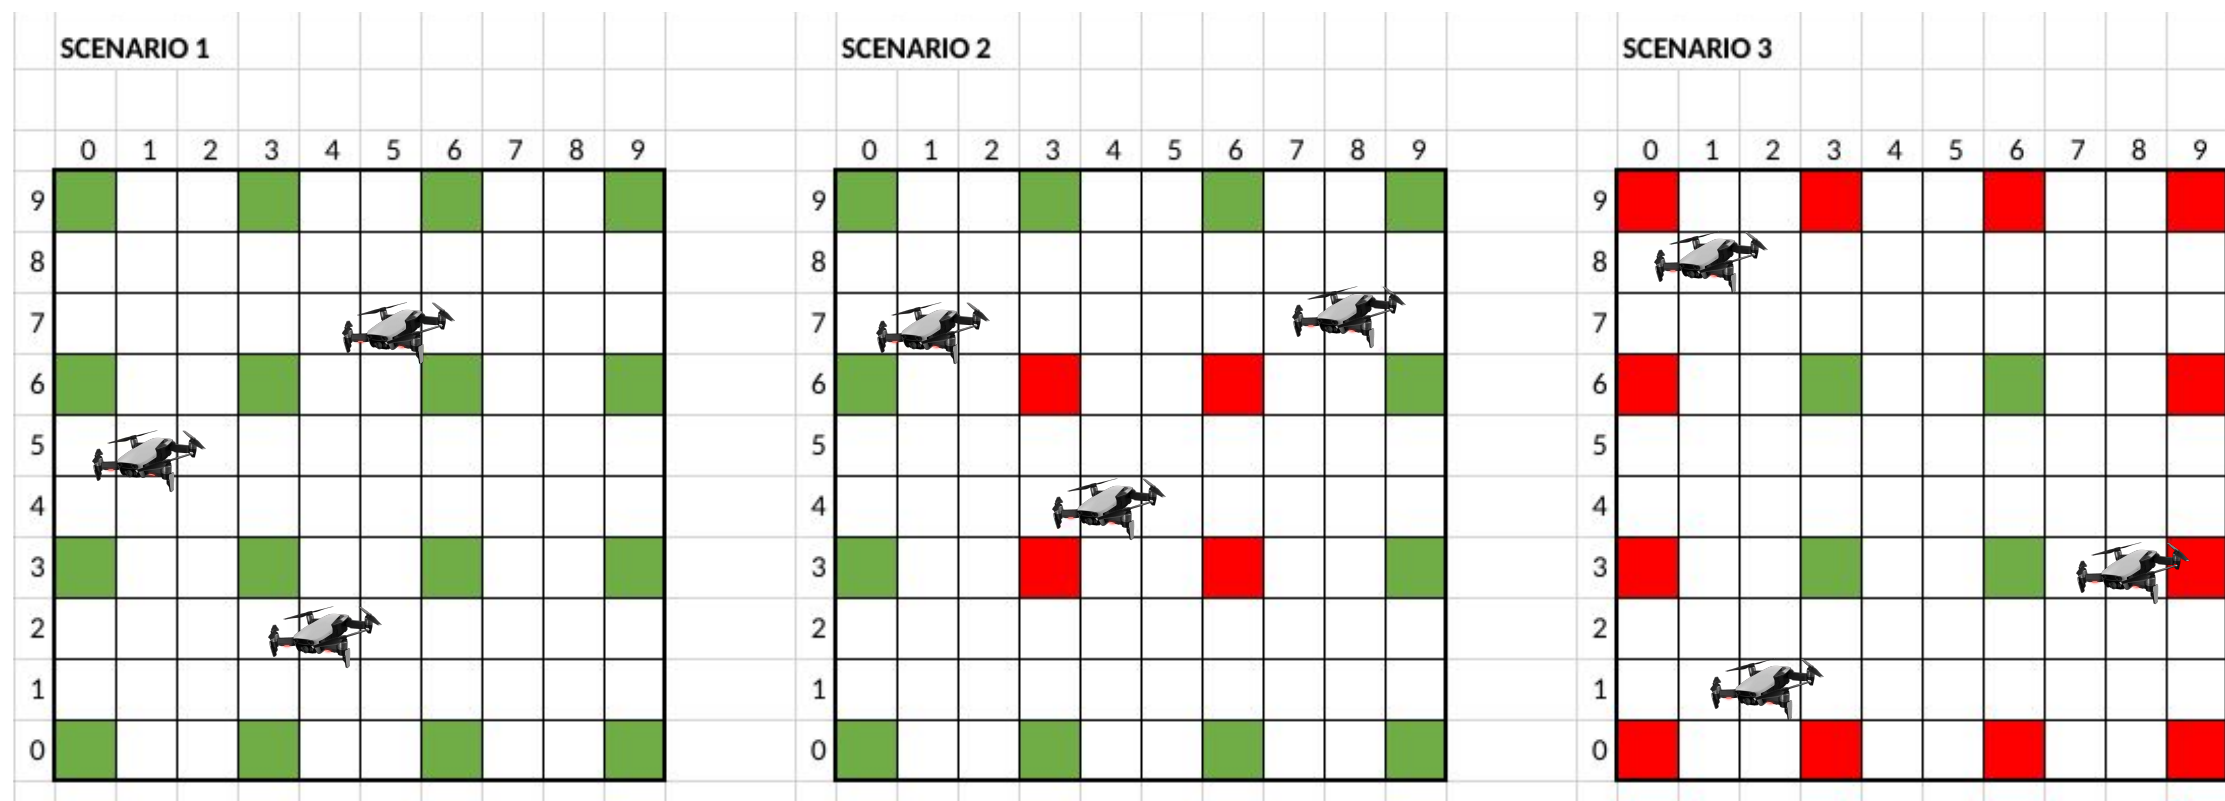
# Trabalho desenvolvido





# Dataset

	Null traffic demand ( $\lambda = 0$ Mbit/s)
	Low traffic demand ( $\lambda = 3$ Mbit/s)
	High Traffic demand ( $\lambda = 10$ Mbit/s)



- Posição dos 3 Drones;
- Altitude de 10 metros;
- *WifiCellRange* de 100 metros
- *WifiChannelNumber* : {36,40,44}
- Métricas a analisar (*meanRxBitrateMbps*, *meanDelayMs*, *meanJitterMs*, *meanPdr*)



# Processamento dos dados

```

Linha de comandos - python -i build_model.py
>>> input_train
array([[[[ 3., 0., 0., ..., 0.,
          0., 3., ], 0., ..., 0.,
          [ 0., 0., ], 0., ..., 0.,
          [ 0., 0., ], 0., ..., 0.,
          ...,
          [ 0., 0., 0., ..., 0.,
            0., 0., ], 0., ..., 0.,
            [ 0., 0., ], 0., ..., 0.,
            [ 3., 0., ], 0., ..., 0.,
            0., 3., ]],
        [[ 3.02953607, 3.06634492, 2.80236837, ..., 0.43139197,
            0.16931388, 0.07336994],
          [ 2.43830285, 2.4803205, 2.60391312, ..., -0.02806965,
            -0.37829206, -0.51786329],
          [ 1.84706962, 1.89600158, 2.03895751, ..., -0.37829206,
            -0.8641997, -1.10909652],
          ...,
          [-1.10909652, -0.8641997, -0.51786329, ..., 0.94374563,
            0.7373873, 0.66460316],
          [-1.70032975, -1.10909652, -1.10909652, ..., 1.31438002,
            1.31438002, 1.25583639],
          [-1.10909652, -1.10909652, -1.70032975, ..., 1.25583639,
            1.84706962, 1.84706962]]],
        ...,
        [[[ 0., 0., 0., ..., 0.,
            0., 0., ], 0., ..., 10.,
            [ 0., 0., ], 0., ..., 3.,
            [ 0., 0., ], 0., ..., 0.,
            ...,
            [ 0., 0., 3., ..., 0.,
              0., 0., ], 0., ..., 3.,
              [ 0., 0., ], 0., ..., 0.,
              [ 0., 0., ], 0., ..., 0.,
              0., 0., ]],
        [[ 7.14390291, 6.14881563, 5.19491291, ..., 4.4517146,
            5.19491291, 6.14881563],
          [ 5.47674311, 4.90466431, 3.80958332, ..., 2.9295496,
            3.80958332, 4.90466431],
          [ 3.80958332, 3.80958332, 2.54694432, ..., 1.48481447,
            2.54694432, 3.80958332],
          ...,
          [-4.52621566, -2.85905587, -1.19189607, ..., 0.18922433,
            1.48481447, 2.9295496 ],
          [-4.52621566, -2.85905587, -1.19189607, ..., 1.48481447,
            2.54694432, 3.80958332],
          [-2.85905587, -2.16849567, -0.79833303, ..., 2.9295496,
            3.80958332, 4.90466431]]]])
>>> throughput_train
array([2.689776, 2.952488, 2.928736, ..., 2.805651, 2.15420875,
       2.665089 ])
>>>

```

Fig 2: Dados de treino

```

#Global Variables
SCENARIO_ROWS = 10
SCENARIO_COLUMNS = 10
SCENARIO_TOPOLOGIES_NO = 200
SCENARIOS_NO = 10
TOPOLOGIES_TRAINING = 128
TOPOLOGIES_VALIDATION = 32
TOPOLOGIES_TESTING = 40
#SCENARIOS_TRAINING = [1, 2, 4, 6, 7, 10]
#SCENARIOS_VALIDATION = [5, 9]
SCENARIOS_TRAINING = [1, 2, 4, 6, 7, 10, 5, 9]
SCENARIOS_VALIDATION = []
SCENARIOS_TEST = [3, 8]
DIVISION_BY_TOPOLOGIES = 0
DISTANCE_ENCODING = 1
NORMALIZE_DATA = 1
USE_TRANSFORMATIONS = 1
CHANNELS_LAST = 0
VALIDATION_SPLIT = 0
USE_CALLBACKS = 0
TEST_RESULTS = 1

```

Fig 3: Tipos de settings usados

# Camadas do Modelo

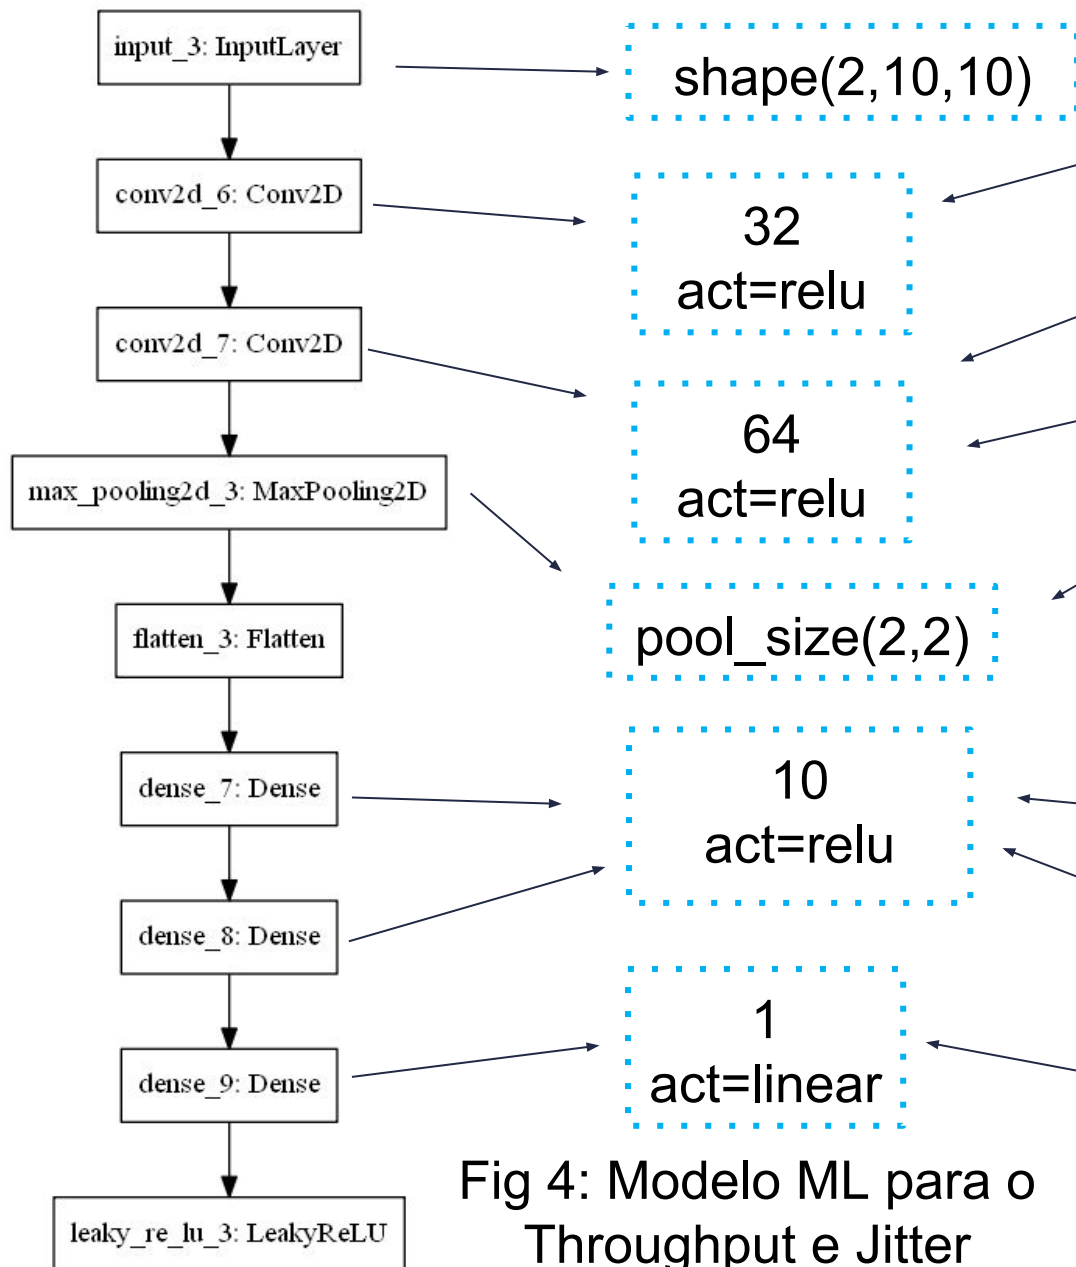


Fig 4: Modelo ML para o Throughput e Jitter

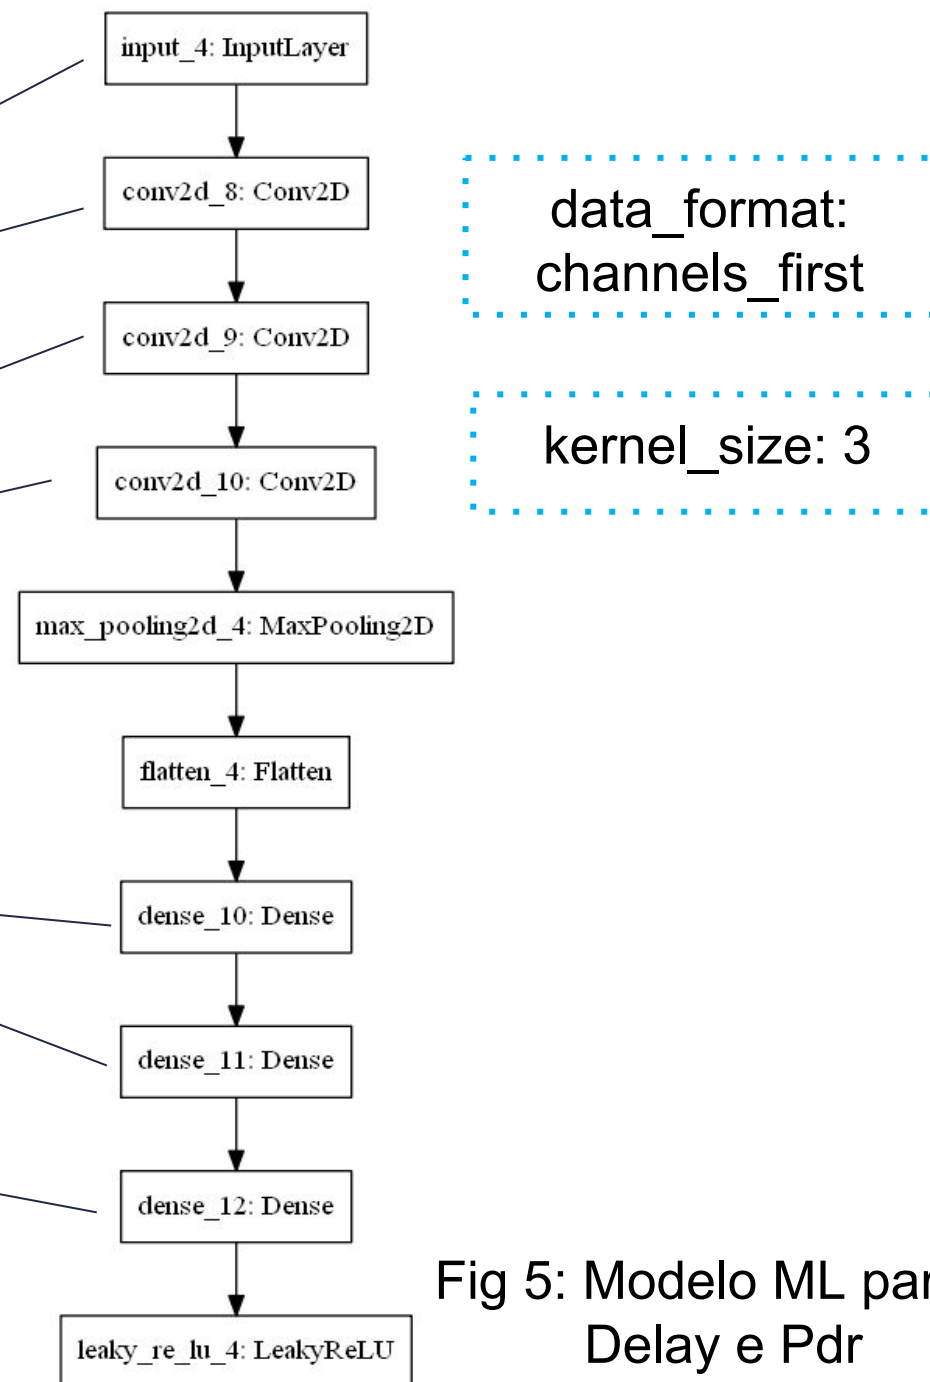
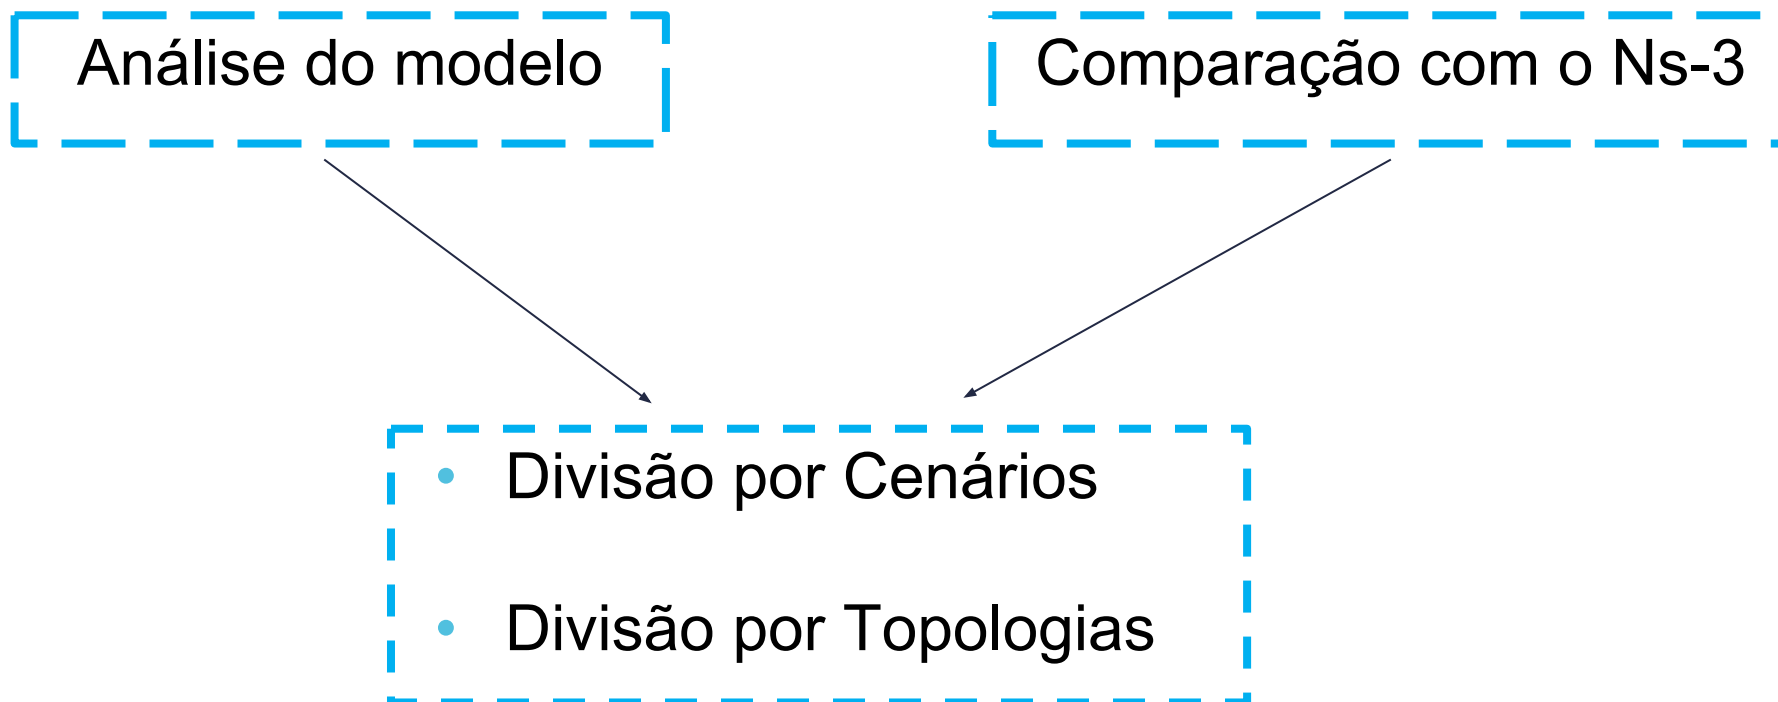


Fig 5: Modelo ML para o Delay e Pdr

# Resultados obtidos





# Resultados obtidos

- Análise do modelo

Train/Test		12800/3200					12800/3200		
Division		Scenarios					Topologies		
		MSE	MAE	MAPE			MSE	MAE	MAPE
	Throughput	0.833	0.762	17.619		Throughput	0.176	0.296	7.976
	Delay	20609.9	388.687	41.118		Delay	39241.7	147.179	18.929
	PDR	0.041	0.172	29.119		PDR	0.003	0.041	6.46


Fig 6: Análise de treino do modelo




# Resultados obtidos

- Análise do modelo

Divisão por Cenários:



Divisão por Topologias:




Throughput Loss


# Resultados obtidos

- Análise do modelo

Divisão por Cenários:



Divisão por Topologias:




Delay Loss




# Resultados obtidos

- Análise do modelo

Divisão por Cenários:



Divisão por Topologias:



Pdr Loss

# Resultados obtidos

- Comparação com o Ns-3

Model Trained By Division	Scenarios			Topologies			All Data		
	Throughput	Delay	Pdr	Throughput	Delay	Pdr	Throughput	Delay	Pdr
(%)	49	66	25	20	48	12	12		34

## Conclusões

No fim deste trabalho conseguimos tirar algumas conclusões importantes para o futuro aprofundamento deste tema:

- o modelo dá bons resultados, mas necessita de mais dados, principalmente cenários, de forma a dar resultados mais próximos da realidade;
- o número de *epochs* de treino, no caso do delay, deveria ser aumentado. Acreditamos que com mais de 100 *epochs* o delay melhora substancialmente;
- o modelo dá melhores resultados quando treinado com *distance encoding*;
- a divisão por topologias nos dados gera um modelo com melhores resultados;



## Feedback

★ O que correu bem?



★ O que correu menos bem?



# Questões?

